

# 基于卷积记忆神经网络的微博短文本情感分析\*

郑 啸 王义真 袁志祥 秦 锋

(安徽工业大学 计算机科学与技术学院 马鞍山 243032)

**摘 要:** 微博短文本情感分析的目的是发现用户对热点事件的观点及态度。已有的方法大多是基于词袋模型,然而,词袋模型无法准确捕获带有情感倾向性的语言表现特征。结合卷积神经网络(CNN)和长短期记忆网络(LSTM)模型的特点,提出了卷积记忆神经网络模型(CMNN),并基于此模型来解决情感分析问题。与传统算法相比,模型避免了具体任务的特征工程设计;与CNN和LSTM相比,模型既能够有效提取短文本局部最优特征,又能够解决远距离的上下文依赖。通过在COAE2014数据集上的实验来验证了模型对微博短文本情感分析的有效性。并与CNN、LSTM以及传统模型SVM做了实验对比,结果表明,模型对于微博短文本情感分析在性能上优于其他3种模型。

**关键词:** 微博短文本; 情感分析; 神经网络; 卷积记忆神经网络

中图分类号: TP391 文献标识码: A 国家标准学科分类代码: 520.60

## Sentiment analysis of micro-blog short text based on convolutional memory neural network

Zheng Xiao Wang Yizhen Yuan Zhixiang Qin Feng

(School of Computer Science and Technology, Anhui University of Technology, Ma'anshan 243032, China)

**Abstract:** The sentiment analysis of micro-blog short text is aimed at finding users' attitude to hot events. The existing methods are mostly based on the bag of words model for sentiment analysis. This paper presents a new model named convolution memory neural network(CMNN) to solve sentiment analysis problems, which combined with the characteristics of the convolutional neural network(CNN) and the long short-term memory neural network(LSTM). Compared with traditional algorithms, the proposed model avoids the specific task of feature engineering design. Compared with CNN and LSTM, this model can effectively extract the characteristics of local optimal features of short text and learn long-term dependencies information. Experiments on the COAE2014 dataset are conducted to verify the proposed model on the micro-blog sentiment analysis. The experimental results show that the proposed model is superior to three models, i. e. SVM, CNN and LSTM.

**Keywords:** micro-blog short text; sentiment classification; neural networks; convolutional memory neural networks

## 0 引 言

近年来随着移动互联网的快速发展,越来越多的用户更方便地通过微博等各种社交媒体来表达自己的观点,发表对热点事件的评论。社交网络已成为人们发表观点和抒发情绪的重要平台,它对社会诸领域的介入和渗透与日俱增,社会影响力日益巨大。根据微博短文本

进行情感倾向性分析是一个具有挑战性的任务,近年来引起了专家学者的关注<sup>[1]</sup>。分析和挖掘微博短文本中所隐藏的情感信息,可以从中了解大众对热点事件的关注程度和舆情情感的变化情况,从而能够辅助识别热点事件和掌握舆情及突发事件的发展状况。此外,微博短文本情感分析的研究,也是自然语言处理和文本挖掘的重要研究方向之一。

目前,国内外的专家学者已对情感分析问题做出了

收稿日期: 2017-08 Received Date: 2017-08

\* 基金项目: 国家重点研发计划(2016YFF020440508)、安徽省科技重大专项(16030901060)、安徽省高校自然科学研究重大项目(KJ2014ZD05)、安徽省高校优秀青年人才支持计划资助项目

一些研究探索,已有研究方法大多数都基于词袋模型。然而,词袋模型<sup>[2,3]</sup>是无法准确捕获带有情感倾向性的语言表现特征。此外,还有很多研究者借助人工标注的情感词典(HowNet)来提高情感分析的准确率。传统机器学习情感分析方法归纳起来有3类:有监督学习、无监督学习以及半监督学习。虽然当前大多数基于有监督学习的情感分析研究取得了不错的效果,但有监督学习依赖于大量人工标注的数据,从而限制了这类方法在其他领域以及跨语言的推广<sup>[4]</sup>。

微博短文本具有口语化、不规范性、主题不明确、上下文有限等特点,传统机器学习对其情感特征提取费时耗力。对于微博短文本的情感分析研究是一项循序渐进、由浅入深的任务,近年来,随着深度学习相关技术的发展,研究人员更倾向于利用深度学习来解决这一任务。例如,利用Recursive Auto-encoder方法试图以一种树形结构来描述文本,能够学习到文本的句法信息<sup>[5]</sup>。利用构建在句法分析树上的循环神经网络(recurrent neural network, RNN)对电影评论文本进行细粒度的情感极性判别<sup>[6]</sup>。将word embedding与卷积神经网络(convolutional neural network, CNN)结合进行句子的分类,获得了非常好的效果<sup>[7]</sup>。CNN虽然能够学习到时间或空间局部特征,避免了人工特征的提取,但是缺乏学习序列相关性的能力。RNN被证明是一种有效解决上下文信息的方法,但该方法存在梯度消失和爆炸的问题。文献[8]指出长短期记忆(long short term memory, LSTM)型RNN可以有效地解决这一问题。与CNN相比,虽然LSTM能够解决序列问题,但是无法提取出平行的特征。为此,本文提出一种基于卷积记忆神经网络模型(convolutional memory neural network, CMNN)的微博短文本情感分析方法,使用CNN的卷积层提取局部特征,作为下一层LSTM网络的输入来完成微博短文本情感分析,从而更好地利用局部平行特征、上下文信息和减少了人工标注的方式来解决微博短文本的情感分类。

## 1 相关工作

情感分析(sentiment analysis),又称倾向性分析,意见抽取(opinion extraction),意见挖掘(opinion mining),情感挖掘(sentiment mining),主观分析(subjectivity analysis),它是对带有情感色彩的主观性文本进行分析、处理、归纳和推理的过程<sup>[9]</sup>。李婷婷等人<sup>[3]</sup>尝试从文本数据中人工构建若干特征,再利用传统的机器学习方法进行情感分类。同时有些研究者从语言学角度出发,Taboada等人<sup>[10]</sup>利用词典中情感词和短语的相关极性和强度,并采用集约化和否定化计算文本的情感得分。Yuan等人<sup>[11]</sup>结合词典和规则来计算文本的情感极性。

这种方法通常的重点是情感评价词语或其组合的极性判断以及极性求和的方法。然而,特征工程的设计耗费人力,它在需要一定的先验知识的同时还依赖于不断深入理解问题和依赖情感知识,其分类效果严重依赖于所构建特征的质量和模型参数的调优。

近年来,越来越多的研究人员青睐于使用深度学习技术来解决文本分类问题<sup>[12]</sup>。深度学习强大的特征学习能力可以从少量的样本集中抓取到数据的本质特征。Socher等人<sup>[5]</sup>利用递归神经网络模型对影评数据进行情感分析,取得了比传统方法更好的效果。Luong等人<sup>[13]</sup>用递归神经网络以明确词的形态结构来建模。Chrupala等人<sup>[14]</sup>提出一个简单的循环网络(simple recurrent network, SRN),从而得到连续的序序列的向量表示,并将此向量作为特征用条件随机场进行分类,解决了字级文本分割和标签的嵌入任务。Santos等人<sup>[15]</sup>提出了基于深度卷积神经网络的分析模型,利用两层卷积层从任意长度的单子和句子中抽取特征。秦锋等人<sup>[16]</sup>引入了隐马尔可夫支持向量机模型,将微博的上下文语境融入模型中,提高了情感极性的识别率。

目前的相关工作中,基于传统机器学习、情感词典资源、人工规则的特征抽取往往依赖于语料领域,而且所抽取的文本特征维数随着抽取规则的增加线性增加。与前者相比,神经网络模型较多考虑的还是将单一模型或者改进模型应用到文本的情感分析,实验效果依赖于原本模型的特点。

## 2 CNN 模型

文本向量化,为文本的向量化的实现提供了基础。结合CNN和LSTM的特点,提出了CMNN模型。该模型首先要将短文本向量化,通过CNN的卷积层抽取短文本的局部最优信息,将其作为LSTM的输入层,并利用误差反向传播算法训练模型。从而CMNN模型不仅可以学习到微博短文本的局部特征,还可以学习到长距离的上下文历史信息。

### 2.1 文本向量化

神经网络的输入是需要将文本数据映射为维的实数向量,即文本向量化。目前,文本向量化的表现方式主要有两种:one-hot representation和distributed representation。one-hot representation是将每个词表示为一个很长的向量,向量的维度是词表大小,通常非常稀疏,且任意两个字间不存在联系、均是孤立的;而distributed representation的方式以低维度的向量来表示,让相关的字在语义上更加接近,通常又称嵌入(embedding)。本文细分为两种表示方式:one hot和word embedding。

one hot:利用分词工具首先将句子进行分词,以词为

单位,将词进行 one-hot 编码,得到“one hot”字典。

word embedding: 利用分词工具首先将句子进行分词,以词为单位。接着利用 word2vec 工具进行词向量的训练,最后得到“word embedding”字典。

## 2.2 基于 CNN 的情感分析模型

CNN 可以学习到文本的局部特征,但无法解决上下文的长期依赖问题。而 LSTM 具有能够学习的长期依赖的能力,能有效利用很宽范围的上下文信息。本文结合两者的特点构建卷积记忆网络模型用以微博短文本的情感分类。如图 1 所示,CMNN 的网络层包括:卷积层、池化层、时序层、输出层。




图1 卷积记忆神经网络模型

Fig.1 Convolutional memory neural network

卷积层(convolutional layer): 利用 CNN 的卷积层抽取文本的局部特征。通过对输入的数据应用滤波器提取局部特征,经过卷积核运算产生特征图(feature map, FM)。本文卷积操作参考了 Kim<sup>[7]</sup>的工作,利用多个大小不同的卷积核对本进行卷积操作,构建新的向量。本文与文献[7]不同之处在于本文重新训练了 word embedding,有效地利用了原始数据特征。由于不同短文本的长度可能不同,情感信息出现的位置也可能不同,所以模型在卷积前对文本进行 padding 操作。模型利用不同卷积核进行卷积操作可以学习到短文本的局部特征,卷积窗口的高度不同,获取文本的局部信息也不同。因此,本文并行使用多个卷积核,学习不同局部的情感信息。经过采样层后将得到微博短文本的局部特征。

给定含有  $n$  个词  $(x_1, x_2, \dots, x_n)$  的短文本  $X$  表示为:

$$X = x_1 \oplus x_2 \oplus \dots \oplus x_n \quad (1)$$

式中:  $\oplus$  为向量拼接操作;  $x_i \in R^k$  是句子第  $i$  个词的  $k$  维度的向量。

卷积核  $w \in R^{h \times k}$  在长度  $h$  的窗口内进行卷积操作,则输出特征为:

$$c_i = f(w \cdot x_{i:i+h-1} + b) \quad (2)$$

式中:  $b \in R$  为偏置项;  $f$  为激活函数。

卷积核  $w$  对文本的长为  $h$  的单元  $\{x_{1:h}, x_{2:h+1}, \dots, x_{n-h+1:n}\}$  进行卷积操作后得到的一个特征图,其中  $c \in R^{n-h+1}$ 。

$$c = [c_1, c_2, \dots, c_{n-h+1}] \quad (3)$$

如式(1)、(3)描述,文本最终被表示成多个特征图。

池化层(pooling layer): 又叫采样层,其用来缩减输入数据的规模进行特征映射层,输出局部最优特征。池化层作用在卷积层之后,是一种非线性的降维的方法。通常的做法是在卷积层的特征上,在一个固定大小的区域上采样一个点,作为下一层网络的输入。采样的方法有:最大值采样(max-pooling)和均值采样(mean-pooling)。本文选用的是 max-pooling,是因为 max-pooling 既能消除非最大值,从而减少上层的计算量;又能提取到不同区域的局部依赖,保持最显著的信息特征。将式(3)得到的特征图  $c$  最大值采样后得到  $\hat{c} = \max\{c\}$ ,即抽取局部最优特征。

时序层(time series layer): 利用 LSTM 能够解决远距离上下文依赖特性学习和存储上下文历史信息的特点,将 LSTM 作为本文模型的时序层。LSTM 是一种特殊的 RNN,与通常的 RNN 相比,代替链式结构(如一个单一的 tanh 层)有 4 个。网络模块的示意图如图 2 所示。

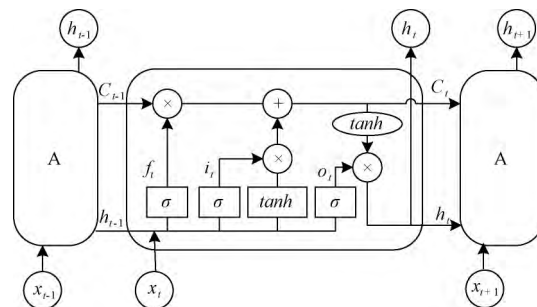


图2 LSTM 神经网络模块

Fig.2 Module of LSTM neural network

LSTM 模型有输入门(input gates)、遗忘门(forget gates)和输出门(output gates) 3 种门结构,这 3 个门分别提供了对网络记忆单元读、写以及重置操作,用以更新和保持记忆单元的状态。记忆单元通过以下 3 种方式进行状态的维护。

1) 决定从单元状态中丢掉哪些信息。由遗忘门的 sigmoid 层做出这些决定。该门读取  $h_{t-1}$  和  $x_t$  输出  $f_t$ 。 $f_t$  是 0 和 1 之间的一个数字,1 表示完全保留信息,0 表示完全丢掉信息。 $f_t$  定义为:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (4)$$

式中:  $W_f$  是权重矩阵;  $b_f \in R$  为偏置项;  $\sigma$  是 logistic sigmoid 激活函数。

2) 决定在单元状态中储存哪些新信息。这分为两个部分,首先,被称为输入门的一个 sigmoid 层决定哪些

值会更新;接着,一个  $\tanh$  层创建新的候选值  $\tilde{C}_t$ 。当前单元状态  $C_t$  是由前一单元状态  $C_{t-1}$  乘以  $f_t$  (丢弃之前决定遗忘的信息) 与新的候选信息  $i_t \cdot \tilde{C}_t$  之和组成。即:

$$i_t = \sigma(W_i \cdot [h_{t-1} \ x_t] + b_i) \quad (5)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1} \ x_t] + b_c) \quad (6)$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (7)$$

式中:  $W_i$  和  $W_c$  是权重矩阵;  $b_i, b_c \in R$  为偏置项;  $\sigma$  是 logistic sigmoid 激活函数。

3) 决定需要输出的信息。同样分为两个部分,首先,运行一个  $\text{sigmoid}$  层决定输出哪些单元状态。接着,使用  $\tanh$  函数和  $\text{sigmoid}$  门限的输出相乘得到输出的信息  $h_t$ , 即:

$$o_t = \sigma(W_o \cdot [h_{t-1} \ x_t] + b_o) \quad (8)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (9)$$

式中:  $x_t$  是输入的当前步骤;  $W_o$  是权重矩阵;  $b_o \in R$  为偏置项;  $\sigma$  是 logistic sigmoid 激活函数。

LSTM 时间序列最后得到的是短文本的最终向量表示,在该网络层输出添加一个  $\text{softmax}$  层。本文使用最小化交叉熵来训练网络模型。对于给定样本  $x^{(i)}$  以及真实标签  $y^{(i)} \in \{1, 2, \dots, k\}$ , 其中  $k$  是可能的极性标签数量,每个样本的估计值  $\hat{y}_j^{(i)} \in [0, 1]$   $j \in \{1, 2, \dots, k\}$ , 其误差可以定义为:

$$L(x^{(i)}, y^{(i)}) = \sum_{j=1}^k 1\{y^{(i)} = j\} \log(\hat{y}_j^{(i)}) \quad (10)$$

其中,  $1\{\text{条件为真}\} = 1$ , 否则  $1\{\text{条件为假}\} = 0$ 。采用随机梯度下降(SGD)来学习模型的参数。

输出层(output layer): 网络的输出是逻辑值,本文采用的  $\text{softmax}$  分类器。

### 2.3 模型训练

微博短文本情感倾向性分类从本质上看仍属于文本分类问题,最终将主观性的微博短文本分为积极和消极两种情感倾向。给定一个短文本  $x$ , 参数集合为  $\theta$  的模型对每个情感极性标签  $\tau \in T$  计算一个得分  $s_\theta(x)_\tau$ 。为了将这些得分转换为给定短文本的情感标签和模型参数集  $\theta$  的条件概率分布  $\beta$  在所有情感标签  $\tau \in T$  的得分进行  $\text{softmax}$  操作:

$$P(\tau | x, \theta) = \frac{e^{s_\theta(x)_\tau}}{\sum_{\forall \tau \in T} e^{s_\theta(x)_\tau}} \quad (11)$$

对式(11)取对数:

$$\log P(\tau | x, \theta) = s_\theta(x)_\tau - \log\left(\sum_{\forall \tau \in T} e^{s_\theta(x)_\tau}\right) \quad (12)$$

本文使用随机梯度下降(SGD)最小化负似然函数:

$$\theta \rightarrow a \sum_{(x, y) \in D} -\log P(y | x, \theta) \quad (13)$$

式中:  $x$  表示训练语料  $D$  的一个文本,  $y$  表示该文本的情感标签。然后使用反向传播算法(back propagation, BP)

计算网络架构梯度。

## 3 实验

### 3.1 实验数据

本文采用 COAE2014 任务 4 微博数据集(表 1 为数据集样例), 该数据集共 40 000 条数据。本文在官方公布的 5 000 条含有极性的微博基础上又人工标注了 1 000 条。本文利用该 6 000 条数据, 进行 10 折交叉验证。并且利用数据集提供的 40 000 条微博作为词向量的训练。

表 1 COAE2014 数据集样例

Table 1 Example of COAE2014 dataset

积极	消极
1) 喜欢蒙牛核桃牛奶~我得去买, 除酸奶外唯一喜欢的。	1) 刚才也接到了。居然问我, 请问贵姓。骚扰电话!
2) 哈哈所以我说我是手机的领导者嘛	2) 三星的手机有点用不惯呀!
3) 奥迪 A6L 的内饰真心算是相当精致...	3) 把翡翠雕成这样真崩溃

### 3.2 词向量的训练与模型超参数设置

本文利用 ICTCLAS 分词工具对全部语料库进行分词, 在对语料库分词前要进行预处理操作, 其中预处理包括: 删除 @user、删除网址、删除话题、删除转发或回复原文等。使用 Google 提供的开源词向量训练工具 word2vec 进行词向量的训练, 其训练参数如表 2 所示, 最终训练得到一个 15 035 的词向量字典。

表 2 word2vec 训练的参数

Table 2 Training parameters of word2vec

word2vec 参数	值
size	128
window	8
sample	0.001
算法选择	Skip-gram

本文 3 种网络训练的超参数设置如表 3 所示, 最小化交叉熵作为损失函数, 使用随机梯度下降算法对模型中的参数进行调整。

### 3.3 实验结果及分析

本文实验的评价指标是准确率(Precision)、召回率(Recall)和 F 值(F-score)。按照表 3 设定的可调参数, 在相同实验环境下对比不同模型的实验效果, 其中以传统词袋模型作为参考模型。词袋模型的特征也是选用了 word2vec 预训练词向量特征, 使用 SVM 开源工具包进行了实验。实验结果如表 4 所示, 单位为百分比。

表3 网络模型的参数

Table 3 Parameters of network models

可调参数	值
卷积的上下文窗口数量	4
卷积的上下文长度	3,4,5,6
CNN 的隐藏层的单元数量	128
LSTM 的隐藏层的单元数量	256
CMNN 的隐藏层的单元数量	256

表4 多个模型的比较结果

Table 4 Comparison results of different models

模型名称	Precision	Recall	F-score
SVM-one hot	77.14	72.73	74.87
SVM-word2vec	79.57	79.86	79.71
CNN-one hot	83.33	83.81	88.57
CNN-word2vec	84.85	82.67	83.75
LSTM-one hot	80.65	75.76	78.13
LSTM-word2vec	82.32	84.85	83.58
CMNN-one hot	86.34	83.32	84.80
CMNN-word2vec	87.88	87.47	87.67

从表4中可以得出结论,神经网络的准确率要高于传统模型。表4带有 one-hot 的形式指的是词向量采用 one hot 方式,而带有 word2vec 的形式指的是词向量是经过 word2vec 预训练得到词向量。

1) 通过 one hot 形式的结果与 word2vec 形式的结果对比,可以发现预先经过训练的词向量作为模型的输入对微博短文本情感分类的准确率要高于未训练的准确率。原因在于经过 word2vec 训练的词向量包含文本的语法、语义信息,而 one hot 形式的词向量丢失了原始文本的这些信息。

2) 通过神经网络模型和传统词袋模型的结果对比,可以发现,神经网络模型的准确率要优于传统词袋模型的准确率。这是由于传统算法结果的好坏依赖于特征的选择,而本文的神经网络情感分类模型能很好地抽取短文本的特征。

3) 通过比较3种模型,可以发现短文本的情感分类的准确率相对而言更依赖于局部最优特征。所以本文很好的结合两种神经网络的优势,提出基于卷积记忆神经网络模型。实验结果表明,本文所提的 CMNN 模型在微博短文本情感分类上具有很好的性能。

## 4 结 论

本文首先使用 CNN 和 LSTM 来进行微博短文本情感分析,并在相同条件下与传统词袋模型做了对比取得优于传统模型的准确率,从实验角度证明了神经网络可用于微博短文本的情感分析。接着将 CNN 的卷积结构

扩展到 LSTM 网络构造了新的卷积记忆神经网络模型,使得模型在挖掘微博短文本局部有效信息的同时,更好地利用了文本的上下文信息,提高了模型对微博短文本情感分析的有效性。每种模型都有其鲜明的特点和不足,如何利用其他模型的优点来弥补自身模型的不足,是改进模型的一种重要思路。

神经网络模型在微博短文本情感分析上的研究还存在很多问题需要进一步探索分析。例如,针对神经网络在 CPU 上训练非常耗时这一问题,可以考虑使用 GPU 或者多个 GPU 并行化来加速神经网络的训练。下一步工作将深入研究如何加快神经网络的训练速度,寻找到更适合情感分析的神经网络学习算法。

## 参考文献

- [1] PANG B, LEE L L. Seeing stars: Exploiting class relationships for sentiment categorization with respect to rating scales [C]. Proceedings of the 43rd Annual Meeting on Association for Computational Linguistics, 2005: 115-124.
- [2] 谢丽星,周明,孙茂松. 基于层次结构的多策略中文微博情感分析和特征抽取[J]. 中文信息学报,2012,26(1): 73-83.  
XIE L X, ZHOU M, SUN M S. Based on the multi-strategy Chinese microblog emotion analysis and feature extraction based on hierarchical structure [J]. Journal of Chinese Information, 2012, 26(1): 73-83.
- [3] 李婷婷,姬东鸿. 基于 SVM 和 CRF 多特征组合的微博情感分析[J]. 计算机应用研究,2015,32(4): 978-981.  
LI T T, JI D H. Analysis of micro-blogs based on SVM and CRF multi-feature combination [J]. Computer Application Research, 2015, 32(4): 978-981.
- [4] 梁军,柴玉梅,原慧斌,等. 基于深度学习的微博情感分析[J]. 中文信息学报,2014,28(5): 155-161.  
LIANG J, CHAI Y M, YUAN H B, etc. Based on in-depth study of weibo emotion analysis [J]. Journal of Chinese Information, 2014, 28(5): 155-161.
- [5] SOCHER R, PENNINGTON J, HUANG E H, et al. Semi-supervised recursive autoencoders for predicting sentiment distributions [C]. Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2011: 151-161.
- [6] SOCHER R, PERELYGIN A, WU J Y, et al. Recursive deep models for semantic compositionality over a sentiment treebank [C]. Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2013: 1631-1642.
- [7] KIM Y. Convolutional neural networks for sentence

- classification [C]. Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2014: 1746 – 1751.
- [8] SAK H, SENIOR A, BEAUFAYS F. Long short-term memory recurrent neural network architectures for large scale acoustic modeling [C]. Proceedings of the Annual Conference of the International Speech Communication Association, 2014: 338-342.
- [9] 赵妍妍, 秦兵, 刘挺. 文本情感分析 [J]. 软件学报, 2010, 21(8): 1834-1848.  
ZHAO Y Y, QIN B, LIU B. Text emotion analysis [J]. Journal of Software, 2010, 21(8): 1834-1848.
- [10] TABOADA M, BROOKE J, TOFILOSKI M, et al. Lexicon-based methods for sentiment analysis [J]. Computational linguistics, 2011, 37(2): 267-307.
- [11] YUAN D, ZHOU Y, LI R, et al. Sentiment analysis of microblog combining dictionary and rules [C]. Proceedings of the IEEE /ACM International Conference on Advances in Social Networks Analysis and Mining, 2014: 785-789.
- [12] 陈龙, 管子玉, 何金红 等. 情感分类研究进展 [J]. 计算机研究与发展 2017 54(6): 1150-1170.  
CHEN L, GUAN Z Y, HE J H, et al. A survey on sentiment classification [J]. Journal of Computer Research and Development 2017 54(6): 1150-1170.
- [13] LUONG T, SOCHER R, MANNING C D. Better word representations with recursive neural networks for morphology [C]. Proceedings of the SIGNLL Conference on Computational Natural Language Learning, 2013: 104-113.
- [14] CHRUPALA G. Text segmentation with character-level text embeddings [C]. Proceedings of the ICML workshop on Deep Learning for Audio, Speech and Language Processing 2013.
- [15] SANTOS C N D, GATTI M. Deep convolutional neural networks for sentiment analysis of short texts [C]. Proceedings of the 25th International Conference on Computational Linguistics, 2014: 69-78.
- [16] 秦锋, 王恒, 郑啸, 等. 基于上下文语境的微博情感分析 [J]. 计算机工程, 2017, 43(3): 241-246, 252.  
QIN F, WANG H, ZHENG X, et al. Micro-blog sentiment analysis based on linguistic context [J]. Computer Engineering 2017 43(3): 241-246, 252.

## 作者简介



郑啸, 博士, 现为安徽工业大学教授, 主要研究方向为计算机网络、云计算与服务计算。

E-mail: xzheng@ahut.edu.cn

**Zheng Xiao**, Ph. D., and now he is a professor in Anhui University of Technology.

His main research interests include service computing and mobile cloud computing.



王义真, 2017 年于安徽工业大学获得硕士学位, 主要研究方向为自然语言处理。

E-mail: 575092800@qq.com

**Wang Yizhen** received M. Sc. from Anhui University of Technology in 2017. His main research interests include natural

language processing.



袁志祥, 硕士, 现为安徽工业大学副教授, 主要研究方向为机器学习, 信息系统应用。

E-mail: zxyuan@ahut.edu.cn

**Yuan Zhixiang**, M. Sc., and now he is an associate professor in Anhui University of Technology. His main research interests include machine learning, and information systems application.



秦锋, 硕士, 现为安徽工业大学教授, 主要研究方向为数据挖掘, 智能计算与计算机网络。

E-mail: fqin@ahut.edu.cn

**Qin Feng**, M. Sc. and now he is a professor in Anhui University of Technology. His main research interests include data mining, intelligence computing, and computer networks.